

Análisis Predictivo de Enfermedad Cardíaca: Cleveland Heart Disease Dataset

Omar García Ramos

Resumen

Este estudio realiza un análisis integral del Cleveland Heart Disease Dataset, ampliado desde sus 14 variables estándar hasta un conjunto de 19 atributos clínicamente validados. La selección de variables se basó en criterios de relevancia médica, consistencia estadística y calidad de registro, complementada con un proceso riguroso de limpieza e imputación de datos. El objetivo central es evaluar la capacidad predictiva de diversos modelos de clasificación para la detección de enfermedad coronaria en su forma binaria (presencia vs. ausencia de enfermedad). Se implementan y comparan modelos de regresión logística, k -nearest neighbors, bosques aleatorios y redes neuronales, además de un análisis exploratorio de separación natural mediante K -means. El estudio busca identificar configuraciones robustas y clínicamente interpretables que contribuyan al diagnóstico temprano de cardiopatía isquémica y a la comprensión de los factores que más influyen en su predicción.

1. Introducción y Contexto Clínico

Las enfermedades cardiovasculares representan una de las principales causas de mortalidad a nivel mundial, siendo la enfermedad coronaria la manifestación más frecuente. La detección temprana y la estratificación precisa del riesgo son cruciales para implementar intervenciones preventivas y terapéuticas efectivas. En este contexto, el conjunto de datos *Heart Disease (Cleveland)* se erige como uno de los referentes clásicos para el estudio y predicción de enfermedad coronaria.

Sus variables integran información clínica, demográfica y diagnóstica, incluyendo factores de riesgo tradicionales (`age`, `sex`, `chol`, `htn`, `lbs`), resultados electrocardiográficos (`restecg`) y parámetros derivados de la prueba de esfuerzo (`cp`, `exang`, `thalach`, `oldpeak`, `slope`). Además, incorpora hallazgos de técnicas de imagen como la fluoroscopia (`ca`) y estudios con talio (`thal`), proporcionando una visión integral del perfil del paciente.

La variable principal del dataset es `num`, que indica el número de vasos coronarios con estenosis $\geq 50\%$. Este umbral define enfermedad coronaria clínicamente significativa: un valor de 0 corresponde a la ausencia de obstrucciones relevantes, mientras que valores de 1 a 4 reflejan la severidad del compromiso vascular. La presencia de al menos un vaso obstruido implica riesgo de isquemia miocárdica, manifestada como angina, cambios electrocardiográficos o disminución de la tolerancia al ejercicio.

1.1. Objetivos del Análisis

El presente estudio tiene como objetivo principal desarrollar y comparar modelos de aprendizaje supervisado para la clasificación binaria de enfermedad cardíaca coronaria significativa a partir de variables clínicas, esto mediante:

- Realizar una limpieza y expansión rigurosa del dataset Cleveland estándar, incorporando variables clínicamente relevantes para enriquecer el poder predictivo de los modelos.
- Implementar y evaluar un conjunto diverso de algoritmos de clasificación, desde modelos lineales interpretables hasta métodos no lineales complejos.
- Identificar el modelo que ofrezca el mejor equilibrio entre sensibilidad y precisión (F1-Score) para su potencial uso en un entorno de apoyo al diagnóstico.
- Explorar, de manera secundaria, la existencia de perfiles de pacientes naturales mediante clustering no supervisado (K-Means).

1.2. Variables de Referencia Estándar

La versión más difundida del dataset utiliza 14 variables consideradas como estándar mínimo para tareas de clasificación. Estas variables, según la

documentación original, se presentan en la Tabla 1.

Cuadro 1: 14 Variables Estándar del Cleveland Heart Disease Dataset

No.	Variable	Descripción
3	age	Edad
4	sex	Sexo (0: F, 1: M)
9	cp	Tipo de dolor torácico
10	trestbps	Presión arterial en reposo
12	chol	Colesterol sérico
16	fbs	Glucosa en ayunas >120 mg/dl
19	restecg	ECG en reposo
32	thalach	Frecuencia cardíaca máxima
38	exang	Angina inducida por ejercicio
40	oldpeak	Depresión del ST
41	slope	Pendiente del ST
44	ca	Vasos coloreados (0–3)
51	thal	Prueba de talio
58	num	Diagnóstico final (0–4 vasos obstruidos)

2. Limpieza e Imputación de Datos

Las versiones más comunes del dataset solo incluyen estas 14 variables, omitiendo información adicional clínicamente relevante. Siguiendo criterios de validez clínica y disponibilidad, se incorporaron cuatro variables complementarias: **htn** (hipertensión), **years** (años fumando), **famhist** (historia familiar de enfermedad coronaria) y **thalrest** (frecuencia cardíaca en reposo).

La decisión de expandir el conjunto de datos se basó en la literatura médica, que reconoce estos factores como predictores establecidos de enfermedad coronaria. Su inclusión busca capturar una perspectiva más completa del perfil de riesgo del paciente y enriquecer el poder predictivo de los modelos. Todas ellas cumplen con niveles aceptables de completitud y aportan información predictiva relevante.

2.1. Proceso de Limpieza y Validación

Se aplicaron rangos fisiológicamente plausibles a cada variable, eliminando registros con valores inconsistentes. Este proceso asegura la calidad de los datos y la validez clínica de los análisis posteriores. La Tabla 2 resume los criterios de filtrado aplicados.

Cuadro 2: Resumen del Filtrado por Criterios de Calidad Clínica

Variable	Registros Eliminados	%
Age	13	4.4 %
Sex	5	1.7 %
Cp	10	3.4 %
Trestbps	8	2.7 %
Chol	11	3.7 %
Fbs	7	2.4 %
Restecg	10	3.4 %
Thalach	7	2.4 %
Exang	5	1.7 %
Oldpeak	2	0.7 %
Slope	8	2.7 %
Ca	3	1.0 %
Thal	9	3.0 %
Num	4	1.3 %
Total real	16	5.4 %

Aunque la suma por variable excede este total, múltiples inconsistencias ocurrieron dentro de los mismos registros. Tras el filtrado, se conservaron 282 observaciones, manteniendo un tamaño muestral adecuado para el análisis.

3. Análisis de Valores Faltantes y Selección de Variables

El análisis de completitud reveló valores faltantes principalmente en variables diagnósticas especializadas (**ca**, **thal**) y en la cuantificación del tabaquismo (**years**), como se muestra en la Tabla 3.

Cuadro 3: Valores Faltantes por Variable

Variable	Completo	Faltantes	%
Ca	280	2	0.7 %
Thal	280	2	0.7 %
Years	277	5	1.8 %
Smoke	0	282	100.0 %
Cigs	277	5	1.8 %
Dm	23	259	91.8 %

Las variables **smoke** y **cigs** fueron descartadas por inconsistencias sistemáticas, mientras que **years** fue retenida por ser la medida más estable de exposición tabáquica. Para las variables con baja proporción de faltantes, se aplicaron estrategias de imputación conservadoras: moda para **ca** y **thal**, y valor cero para **years** en casos aislados, bajo supuestos clínicamente razonables.

La selección final de dieciocho variables proporciona un equilibrio adecuado entre relevancia clínica, integridad metodológica y capacidad predictiva, estableciendo una base sólida para el modelado predictivo.

4. Modelos de Clasificación

El enfoque de este estudio se centra en un problema de clasificación binaria, cuyo objetivo es determinar si un paciente presenta o no enfermedad coronaria significativa. Para ello, la variable diagnóstica **num** del Cleveland Heart Disease Dataset se transforma en una etiqueta binaria donde el valor 0 representa la ausencia de estenosis coronaria relevante, mientras que cualquier valor entre 1 y 4 indica la presencia de uno o más vasos con una obstrucción mayor o igual al 50 %.

La elección de un enfoque binario sobre uno multiclase se fundamenta en dos aspectos clave: (1) la necesidad clínica prioritaria de identificar pacientes que requieren intervención versus aquellos que no, y (2) las limitaciones en la interpretabilidad de las variables ordinales del dataset, particularmente en **num** donde la relación entre los valores 1-4 y la severidad real no está completamente documentada.

4.1. Regresión Logística con Optimización de Umbral

La regresión logística modela la probabilidad de pertenencia a una clase mediante una función sigmoide. Para la clasificación binaria de enfermedad cardíaca, el modelo estima:

$$P(y = 1|\mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \beta^T \mathbf{x})}}$$

Se implementó optimización del umbral de clasificación mediante validación cruzada de 5 pliegues, determinando $\tau^* = 0,5049$ que maximiza el F1-Score, balanceando el compromiso clínico entre falsos negativos y falsos positivos. Este modelo fue seleccionado por su interpretabilidad y capacidad para proporcionar coeficientes que cuantifican el impacto de cada variable en el riesgo de enfermedad.

4.2. Análisis Discriminante Lineal de Fisher

Este método busca la proyección lineal que maximiza la separación entre clases. Calcula el vector discriminante $\mathbf{w}$ que maximiza el criterio de Fisher:

$$J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}}$$

donde $\mathbf{S}_B$ es la matriz de dispersión entre clases y $\mathbf{S}_W$ la matriz de dispersión intra-clase. Los datos se proyectan como $z = \mathbf{w}^T \mathbf{x}$ y se clasifican mediante un umbral óptimo $\tau^* = 0,5460$. Este enfoque es particularmente efectivo cuando las clases son linealmente separables.

4.3. Random Forest

Agrupación que construye múltiples árboles de decisión con muestreo aleatorio de datos y características. Cada árbol $h_t(\mathbf{x})$ vota en la predicción final, se configuró con 100 árboles, profundidad máxima 10 y balance automático de clases mediante el parámetro `class_weight`.

4.4. K-Vecinos Más Cercanos (KNN)

Método no paramétrico basado en instancias que clasifica según la mayoría entre los k ejemplos más cercanos en el espacio de características. La distancia euclidiana calcula proximidad:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{m=1}^p (x_{im} - x_{jm})^2}$$

Se optimizó $k = 17$ mediante validación cruzada maximizando F1-Score, capturando patrones locales en los datos. Este modelo es sensible a la escala de las variables, por lo que todas las características fueron estandarizadas previamente.

4.5. Red Neuronal

Se implementó una red neuronal con arquitectura 64-128-128-64-32-8-1, utilizando funciones de activación ReLU en las capas ocultas y sigmoide en la capa de salida para la probabilidad binaria. El modelo se entrenó con el optimizador Adam durante 150 épocas y *batch size* de 32.

Se optimizó el umbral de clasificación a 0.415 para mejorar el balance entre métricas críticas, priorizando la sensibilidad sin comprometer excesivamente la precisión. La arquitectura profunda permite capturar interacciones no lineales complejas entre las variables clínicas.

5. Modelado y Resultados

Se entrenaron y evaluaron cinco modelos de clasificación bajo condiciones controladas para garantizar reproducibilidad. Todos los modelos utilizaron la misma semilla aleatoria (42) en la división train-test (70 %-30 %) y preprocesamiento de datos, permitiendo comparación justa entre algoritmos. La optimización de hiperparámetros se realizó mediante validación cruzada de 5 pliegues en el conjunto de entrenamiento. La Tabla 4 presenta un resumen comparativo de su rendimiento en el conjunto de prueba.

Cuadro 4: Comparación del Desempeño de Modelos de Clasificación

Modelo	Exactitud	Precisión	Sensibilidad	F1-Score	Especificidad
Regresión Logística	0.8596	0.8696	0.8000	0.8333	0.9062
Fisher LDA	0.8421	0.9000	0.7200	0.8000	0.9375
Random Forest	0.8421	0.8636	0.7600	0.8085	0.9062
Red Neuronal	0.8596	0.8148	0.8800	0.8462	0.8438
KNN (K=17)	0.8070	0.7917	0.7600	0.7755	0.8438

Considerando el contexto clínico donde tanto falsos negativos (enfermos no detectados) como falsos positivos (costos innecesarios) conllevan consecuencias significativas, se selecciona la **Red Neuronal** como el modelo más apropiado. Su superior balance evidenciado en el F1-Score más alto (0.8462), combinado con la mayor sensibilidad (88.0 %) para detectar casos positivos, la posiciona como la opción más confiable para apoyo al diagnóstico médico. La optimización de umbral a 0.415 permitió alcanzar este equilibrio óptimo entre métricas críticas.

5.1. Análisis de Clustering con K-Means

El algoritmo K-Means identificó tres perfiles clínicos naturales que trascienden la simple clasificación binaria de enfermedad. Como se observa en la Figura 1, para $k=3$ los clusters muestran una separación visualmente discernible cuando se proyectan en los dos primeros componentes principales, validando la existencia de subpoblaciones distintas dentro del dataset.




Figura 1: Clusters usando los 2 componentes principales para $k = 2, 3, 4$ agrupaciones. Se observa que $k=3$ proporciona la separación más clínicamente interpretable.

- **Cluster 0 - Mujeres no fumadoras de bajo riesgo:** Compuesto predominantemente por mujeres (76 %) no fumadoras o con historial limitado de tabaquismo, presentando baja prevalencia de factores de riesgo cardiovascular y mínima evidencia de enfermedad coronaria (solo 18.1 % con enfermedad).
- **Cluster 1 - Hombres fumadores con enfermedad severa:** Grupo compuesto principalmente por hombres (87 %) fumadores de larga antigüedad, caracterizado por enfermedad coronaria avanzada con múltiples vasos afectados, isquemia marcada en pruebas de esfuerzo, y alta prevalencia de angina. Este cluster concentra el 84 % de todos los casos severos.
- **Cluster 2 - Hombres fumadores jóvenes de riesgo intermedio:** Pacientes masculinos (85 %) significativamente más jóvenes (47.8 años) pero con historial de tabaquismo prolongado. A pesar del factor de riesgo del tabaco, presentan baja prevalencia de enfermedad establecida (25 %) y se caracterizan principalmente por casos leves.

El análisis revela que el tabaquismo y el género son factores determinantes en la formación de clusters naturales, con implicaciones importantes para estrategias de prevención diferenciadas por grupo de riesgo.

6. Limitaciones y Trabajo Futuro

El estudio enfrenta varias limitaciones inherentes al dataset original. La documentación incompleta de variables clave como `thal` (valores 1-7 sin significado clínico claro), `slope` (valores inconsistentes entre centros), y `num` (relación ordinal no completamente especificada) introduce incertidumbre en la interpretación de resultados. Además, el formato original del dataset presentaba desafíos técnicos significativos para su lectura y procesamiento, con múltiples archivos distribuidos y estructuras de datos heterogéneas.

A pesar de estas dificultades, se logró capturar y replicar la información clínica esencial en el dataset procesado, conservando la integridad de las variables más relevantes para el análisis predictivo. Cabe destacar que durante este proceso de estandarización, se identificó que la variable `years` (años fumando) no estaba disponible en el formato final utilizado para el modelado, lo

que podría haber enriquecido el análisis de los perfiles de riesgo identificados mediante clustering.

El análisis de clustering reveló tres perfiles naturales de pacientes que trascienden la clasificación binaria, destacando el papel determinante del género y el tabaquismo en la estratificación del riesgo cardiovascular. Estos hallazgos subrayan la importancia de considerar subpoblaciones específicas en el diseño de estrategias preventivas y programas de intervención temprana.

La decisión de emplear clasificación binaria en lugar de multiclase se basó en las limitaciones de documentación y en el objetivo clínico primario de discriminar entre pacientes que requieren intervención versus aquellos que no. Sin embargo, sería conveniente explorar enfoques de clasificación multiclase en trabajos futuros, a pesar del desbalance inherente entre las categorías de severidad. Técnicas avanzadas de balanceo de clases y modelos específicamente diseñados para datos desbalanceados podrían superar esta limitación y proporcionar una estratificación más granular del riesgo cardiovascular.

A pesar de las limitaciones documentales y técnicas del dataset original, el enfoque metodológico implementado -caracterizado por una limpieza rigurosa, selección criteriosa de variables y validación exhaustiva- proporciona un marco robusto para el análisis predictivo en cardiología. La capacidad de replicar exitosamente la información clínica desde formatos complejos hasta un conjunto de datos estructurado y analíticamente viable representa un logro significativo del presente trabajo.

Referencias

- [1] Shrestha, D. (2024). Advanced Machine Learning Techniques for Predicting Heart Disease: A Comparative Analysis Using the Cleveland Heart Disease Dataset. *Applied Medical Informatics*, 46(3). Disponible en: <https://ami.info.umfcluj.ro/index.php/AMI/article/view/1060>
- [2] Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1989). Heart Disease Dataset. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C52P4X>
- [3] Detrano, R. C., Jánosi, A., Steinbrunn, W., Pfisterer, M. E., Schmid, J. J., Sandhu, S., Guppy, K. H., Lee, S., & Froelicher, V. (1989). International application of a new probability algorithm for the diagnosis of coronary artery disease. *The American Journal of Cardiology*, 64(5), 304-310.