

Análisis Predictivo de Enfermedad Cardíaca

Cleveland Heart Disease Dataset

Omar Garcia Ramos

Contenido

- 1 Introducción y Contexto
- 2 Limpieza y Preparación de Datos
- 3 Modelos Implementados
- 4 Resultados y Métricas
- 5 Conclusiones y Trabajo Futuro

Importancia del Problema





Figura: Arterias Coronarias

Angiograma



Variables del Dataset - Pruebas Diagnósticas

Electrocardiograma en reposo (restecg)

¿Qué mide? Anomalías eléctricas del corazón en reposo

Valores: 0=Normal, 1=Anomalías menores, 2=Hipertrofia ventricular

Prueba de esfuerzo

thalach: Frecuencia cardíaca máxima (latidos/minuto)

exang: ¿Dolor de pecho durante ejercicio? (0=No, 1=Sí)

oldpeak: Depresión del segmento ST (milímetros)

slope: Pendiente del segmento ST (1=Sube, 2=Plano, 3=Baja)

Imágenes diagnósticas

ca (Fluoroscopia): Número de vasos coronarios visibles (0-3)

thal (Talio): Resultado de prueba de perfusión

3=Normal, 6=Defecto fijo, 7=Defecto reversible

Variables del Dataset - Factores de Riesgo y Síntomas

Factores de Riesgo Cardiovascular

htn: Hipertensión arterial (0=No, 1=Sí)

chol: Colesterol sérico (mg/dl)

fbs: Azúcar en ayunas > 120mg/dl (0=No, 1=Sí)

Síntomas y Signos Clínicos

cp: Tipo de dolor torácico (1-4 tipos)

trestbps: Presión arterial en reposo (mmHg)

Variable Objetivo

num: Número de vasos coronarios obstruidos 50 % (0-4)

Transformación: Convertido a binario

Formato de Datos

```
-9 2 -9 1 2 1 1 1
1 1 -9 -9 name
298 0 47 1 -9 -9 -9
-9 3 130 1 253 -9 0 0
0 -9 1 0 5 23 84 0
0 0 0 0 1 9.5 -9 11
179 65 170 82 130 80 0 0
0 1 -9 55 0 -9 -9 -9
-9 -9 -9 3 -9 -9 -9 5
24 84 0 1 1 1 -9 1
-9 1 -9 1 1 1 1 1
1 1 -9 -9 name
299 0 55 0 -9 -9 -9
-9 4 128 0 2044 1 44 1 40 0 0
0.4 0 0 0
0.4 0 0
0 1 -9
0 1 -9
75 8105 1 105 1 18 1018 101881 1-9 3 -9 -9-9 3 -9 -9- -4
94
94 4 -9 1
-9 1 -9 1 000 0-9 -9 -9
```

Figura: Datos Originales Cleveland

- Formato complejo y distribuido
- Múltiples archivos heterogéneos

```
63.0,1.0,1.0,145.0,233.0,1.0,2.0,150.0,0.0,2.3,3.0,0.0,6.0,0
67.0,1.0,4.0,160.0,286.0,0.0,2.0,108.0,1.0,1.5,2.0,3.0,3.0,2
67.0,1.0,4.0,120.0,229.0,0.0,2.0,129.0,1.0,2.6,2.0,2.0,7.0,1
37.0,1.0,3.0,130.0,250.0,0.0,0.0,187.0,0.0,3.5,3.0,0.0,3.0,0
41.0,0.0,2.0,130.0,204.0,0.0,2.0,172.0,0.0,1.4,1.0,0.0,3.0,0
56.0,1.0,2.0,120.0,236.0,0.0,0.0,178.0,0.0,0.8,1.0,0.0,3.0,0
62.0,0.0,4.0,140.0,268.0,0.0,2.0,160.0,0.0,3.6,3.0,2.0,3.0,3
57.0,0.0,4.0,120.0,354.0,0.0,0.0,163.0,1.0,0.6,1.0,0.0,3.0,0
63.0,1.0,4.0,130.0,254.0,0.0,2.0,147.0,0.0,1.4,2.0,1.0,7.0,2
```

Figura: Datos Procesados

- Estructura unificada y estandarizada
- 14 variables clínicamente validadas
- Datos limpios y consistentes

Expansión del Dataset

Cuadro: Variables adicionales incorporadas

Variable	Descripción
htn	Hipertensión arterial
years	Años fumando (exposición tabáquica)
famhist	Historia familiar de enfermedad coronaria
thalrest	Frecuencia cardíaca en reposo

- Base estándar: 14 variables → Expandida: 18 variables
- Criterio: Relevancia clínica y completitud de datos

Proceso de Limpieza




Figura: Proceso de filtrado por criterios de calidad clínica

- Filtrado por rangos fisiológicos plausibles
- 282 observaciones conservadas

Valores Faltantes

Cuadro: Análisis de completitud por variable

Variable	Faltantes	%
Ca	2	0.7 %
Thal	2	0.7 %
Years	5	1.8 %
Smoke	282	100.0 %
Cigs	5	1.8 %
Dm	259	91.8 %

- **Descartadas:** smoke, cigs, dm (inconsistencias sistemáticas)
- **Imputadas:** ca, thal (moda), years (cero - supuesto clínico)

Regresión Logística




Figura: Matriz de Confusión y optimización de Umbral

- **Umbral óptimo:** 0.5049
- **Ventajas:** Interpretabilidad
- **Coeficientes:** Impacto de variables
- **Optimización:** Maximización F1-Score

Discriminante Fisher





Figura: Matriz de Confusión y optimización de Umbral

- **Score óptimo:** 0.546
- **Ventajas:** Interpretabilidad
- **Optimización:** Maximización F1-Score

Random Forest



- **100 árboles**, profundidad máxima 10
- **Maximización** de F1

Figura: Matriz de confusión y optimización de Umbral

Red Neuronal Artificial




Figura: Arquitectura y entrenamiento

- **Arquitectura:** 64-128-128-64-32-8-1
- **Activación:** ReLU (ocultas), Sigmoide (salida)
- **Optimizador:** Adam, 150 épocas
- **Umbral:** 0.415 (optimizado)

Resumen de Importancia de Variables y Variables Clave

Resultados obtenidos con las tres metodologías:

Random Forest

- thal: 0.149
- cp: 0.146
- oldpeak: 0.121

Coefficiente de Fisher (separación de clases)

- ca: 0.618
- thal: 0.515
- cp: 0.409

Regresión Logística


- ca: $\beta = 1,29,$
- sex: $\beta = 0,69,$
- thal: $\beta = 0,66,$

Diferencia entre ca, thal y num:

- **ca** (Coronary Arteries): Número de vasos principales (0–3) con estenosis $> 50\%$. *Describe cuántas arterias están físicamente obstruidas.*
- **thal** (Thallium Stress Test): Resultado de la prueba de esfuerzo con talio: 3 = normal, 6 = defecto fijo, 7 = defecto reversible. *Mide perfusión: funcionalidad del flujo sanguíneo.*
- **num** (Diagnóstico final): Grado de enfermedad coronaria según angiografía: 0 = sano, 1–4 = severidad creciente (hasta 4 vasos afectados). *Es la variable objetivo: resume la gravedad total.*

Análisis de Clustering - K-Means

Método del Codo para Determinar K Óptimo



Análisis de Clustering - K-Means




Figura: Perfiles de pacientes identificados (k=3)

Distribución Clínica por Nivel de Severidad (K=3)

- **Cluster 0 (83 pacientes):** Predominantemente sanos, con sólo 18 % mostrando algún grado de enfermedad.
 - Sano: 68 (81.9 %)
 - Leve: 11 (13.3 %)
 - Moderado: 2 (2.4 %)
 - Severo: 2 (2.4 %)
- **Cluster 1 (95 pacientes):** Grupo clínicamente crítico. Alta concentración de enfermedad moderada a severa.
 - Sano: 11 (11.6 %)
 - Leve: 21 (22.1 %)
 - Moderado: 25 (26.3 %)
 - Severo: 27 (28.4 %)
- **Cluster 2 (104 pacientes):** Riesgo intermedio. Mayor proporción de pacientes sanos, pero con presencia notable de casos leves.
 - Sano: 78 (75.0 %)

Variables Más Relevantes que Diferencian los Clusters

Cluster 0: Perfil de Bajo Riesgo

- Mayoría mujeres (76 %)
- Marcadores clínicos consistentemente bajos
- **Reducciones marcadas:**
 - sex: -64.4 %
 - years: -58.3 %
 - exang: -48.3 %

Cluster 1: Perfil de Alto Riesgo

- Predominio masculino (87 %)
- Alta prevalencia de fumadores
- **Aumentos importantes:**
 - exang: +113.0 %
 - ca: +91.5 %
 - oldpeak: +82.2 %

Cluster 2: Riesgo Intermedio

- Hombres jóvenes (edad media 47.8)
- **Disminuciones clave:**
 - exang: -64.6 %
 - oldpeak: -50.9 %
 - ca: -49.0 %
 - restecg: -45.0 %

Perfiles de Pacientes Identificados

Cluster 0

- Mujeres (76 %)
- No fumadoras
- Bajo riesgo
- 18.1 % enfermedad

Cluster 1

- Hombres (87 %)
- Fumadores
- Enfermedad severa
- 84 % casos severos

Cluster 2

- Hombres (85 %)
- Jóvenes (47.8 años)
- Riesgo intermedio
- 25 % enfermedad

Limitaciones Identificadas

- **Tamaño muestral:** 282 observaciones
- **Desbalance de clases:** Afecta métricas
- **Variables faltantes:** cigs no disponible en formato final
- **Formato complejo:** Dificultades en lectura original

Conclusiones

- **Red Neuronal:** Modelo óptimo (F1-Score: 0.8462)
- **Clustering:** Identificación de 3 perfiles naturales
- **Variables clave:** Género y tabaquismo determinantes
- **Metodología robusta:** Limpieza rigurosa y validación exhaustiva

- **Clasificación multiclase:** A pesar del desbalance
- **Variables adicionales:** Estilo de vida.

¡Gracias!

¿Preguntas?