

Análisis Predictivo de Enfermedad Cardíaca

Cleveland Heart Disease Dataset

Omar Garcia Ramos

Contenido

- 1 Introducción y Contexto
- 2 Limpieza y Preparación de Datos
- 3 Modelos Implementados
- 4 Resultados y Métricas
- 5 Conclusiones y Trabajo Futuro

Importancia del Problema





Figura: Arterias Coronarias

Angiograma



Variables del Dataset - Pruebas Diagnósticas

Electrocardiograma en reposo (restecg)

¿Qué mide? Anomalías eléctricas del corazón en reposo

Valores: 0=Normal, 1=Anomalías menores, 2=Hipertrofia ventricular

Prueba de esfuerzo

thalach: Frecuencia cardíaca máxima (latidos/minuto)

exang: ¿Dolor de pecho durante ejercicio? (0=No, 1=Sí)

oldpeak: Depresión del segmento ST (milímetros)

slope: Pendiente del segmento ST (1=Sube, 2=Plano, 3=Baja)

Imágenes diagnósticas

ca (Fluoroscopia): Número de vasos coronarios visibles (0-3)

thal (Talio): Resultado de prueba de perfusión

3=Normal, 6=Defecto fijo, 7=Defecto reversible

Variables del Dataset - Factores de Riesgo y Síntomas

Factores de Riesgo Cardiovascular

htn: Hipertensión arterial (0=No, 1=Sí)

chol: Colesterol sérico (mg/dl)

fbs: Azúcar en ayunas > 120mg/dl (0=No, 1=Sí)

Síntomas y Signos Clínicos

cp: Tipo de dolor torácico (1-4 tipos)

trestbps: Presión arterial en reposo (mmHg)

Variable Objetivo

num: Número de vasos coronarios obstruidos 50 % (0-4)

Transformación: Convertido a binario

Formato de Datos

```
-9 2 -9 1 2 1 1 1
1 1 -9 -9 name
298 0 47 1 -9 -9 -9
-9 3 130 1 253 -9 0 0
0 -9 1 0 5 23 84 0
0 0 0 0 1 9.5 -9 11
179 65 170 82 130 80 0 0
0 1 -9 55 0 -9 -9 -9
-9 -9 -9 3 -9 -9 -9 5
24 84 0 1 1 1 -9 1
-9 1 -9 1 1 1 1 1
1 1 -9 -9 name
299 0 55 0 -9 -9 -9
-9 4 128 0 2044 1 44 1 40 0 0
0.4 0 0 0
0.4 0 0
0 1 -9
0 1 -9
75 8105 1 105 1 18 1018 101881 1-9 3 -9 -9-9 3 -9 -9- -4
94
94 4 -9 1
-9 1 -9 1 000 0-9 -9 -9
```

Figura: Datos Originales Cleveland

- Formato complejo y distribuido
- Múltiples archivos heterogéneos

```
63.0,1.0,1.0,145.0,233.0,1.0,2.0,150.0,0.0,2.3,3.0,0.0,6.0,0
67.0,1.0,4.0,160.0,286.0,0.0,2.0,108.0,1.0,1.5,2.0,3.0,3.0,2
67.0,1.0,4.0,120.0,229.0,0.0,2.0,129.0,1.0,2.6,2.0,2.0,7.0,1
37.0,1.0,3.0,130.0,250.0,0.0,0.0,187.0,0.0,3.5,3.0,0.0,3.0,0
41.0,0.0,2.0,130.0,204.0,0.0,2.0,172.0,0.0,1.4,1.0,0.0,3.0,0
56.0,1.0,2.0,120.0,236.0,0.0,0.0,178.0,0.0,0.8,1.0,0.0,3.0,0
62.0,0.0,4.0,140.0,268.0,0.0,2.0,160.0,0.0,3.6,3.0,2.0,3.0,3
57.0,0.0,4.0,120.0,354.0,0.0,0.0,163.0,1.0,0.6,1.0,0.0,3.0,0
63.0,1.0,4.0,130.0,254.0,0.0,2.0,147.0,0.0,1.4,2.0,1.0,7.0,2
```

Figura: Datos Procesados

- Estructura unificada y estandarizada
- 14 variables clínicamente validadas
- Datos limpios y consistentes

Expansión del Dataset

Cuadro: Variables adicionales incorporadas

Variable	Descripción
htn	Hipertensión arterial
years	Años fumando (exposición tabáquica)
famhist	Historia familiar de enfermedad coronaria
thalrest	Frecuencia cardíaca en reposo

- Base estándar: 14 variables → Expandida: 18 variables
- Criterio: Relevancia clínica y completitud de datos

Proceso de Limpieza




Figura: Proceso de filtrado por criterios de calidad clínica

- Filtrado por rangos fisiológicos plausibles
- 282 observaciones conservadas

Valores Faltantes

Cuadro: Análisis de completitud por variable

Variable	Faltantes	%
Ca	2	0.7 %
Thal	2	0.7 %
Years	5	1.8 %
Smoke	282	100.0 %
Cigs	5	1.8 %
Dm	259	91.8 %

- **Descartadas:** smoke, cigs, dm (inconsistencias sistemáticas)
- **Imputadas:** ca, thal (moda), years (cero - supuesto clínico)

Regresión Logística




Figura: Matriz de Confusión y optimización de Umbral

- **Umbral óptimo:** 0.5049
- **Ventajas:** Interpretabilidad
- **Coeficientes:** Impacto de variables
- **Optimización:** Maximización F1-Score

Discriminante Fisher




Figura: Matriz de Confusión y optimización de Umbral

- **Score óptimo:** 0.546
- **Ventajas:** Interpretabilidad
- **Optimización:** Maximización F1-Score

Random Forest




Figura: Matriz de confusión y optimización de Umbral

- **100 árboles**, profundidad máxima 10
- **Maximización** de F1

Red Neuronal Artificial




Figura: Arquitectura y entrenamiento

- **Arquitectura:** 64-128-128-64-32-8-1
- **Activación:** ReLU (ocultas), Sigmoide (salida)
- **Optimizador:** Adam, 150 épocas
- **Umbral:** 0.415 (optimizado)


Comparativa de Modelos

Cuadro: Desempeño en conjunto de prueba

Modelo	Exactitud	Precisión	Sensibilidad	F1
Regresión Logística	0.8596	0.8696	0.8000	0.8333
Fisher LDA	0.8421	0.9000	0.7200	0.8000
Random Forest	0.8421	0.8636	0.7600	0.8085
Red Neuronal	0.8596	0.8148	0.8800	0.8462
KNN (K=17)	0.8070	0.7917	0.7600	0.7755

Análisis de Clustering - K-Means

Método del Codo para Determinar K Óptimo



Análisis de Clustering - K-Means




Figura: Perfiles de pacientes identificados (k=3)

Distribución Clínica por Nivel de Severidad (K=3)

- **Cluster 0 (83 pacientes):** Predominantemente sanos, con sólo 18 % mostrando algún grado de enfermedad.
 - Sano: 68 (81.9 %)
 - Leve: 11 (13.3 %)
 - Moderado: 2 (2.4 %)
 - Severo: 2 (2.4 %)
- **Cluster 1 (95 pacientes):** Grupo clínicamente crítico. Alta concentración de enfermedad moderada a severa.
 - Sano: 11 (11.6 %)
 - Leve: 21 (22.1 %)
 - Moderado: 25 (26.3 %)
 - Severo: 27 (28.4 %)
- **Cluster 2 (104 pacientes):** Riesgo intermedio. Mayor proporción de pacientes sanos, pero con presencia notable de casos leves.
 - Sano: 78 (75.0 %)

Variables Más Relevantes que Diferencian los Clusters

Cluster 0: Perfil de Bajo Riesgo

- Mayoría mujeres (76 %)
- Marcadores clínicos consistentemente bajos
- **Reducciones marcadas:**
 - sex: -64.4 %
 - years: -58.3 %
 - exang: -48.3 %

Cluster 1: Perfil de Alto Riesgo

- Predominio masculino (87 %)
- Alta prevalencia de fumadores
- **Aumentos importantes:**
 - exang: +113.0 %
 - ca: +91.5 %
 - oldpeak: +82.2 %

Cluster 2: Riesgo Intermedio

- Hombres jóvenes (edad media 47.8)
- **Disminuciones clave:**
 - exang: -64.6 %
 - oldpeak: -50.9 %
 - ca: -49.0 %
 - restecg: -45.0 %

Perfiles de Pacientes Identificados

Cluster 0

- Mujeres (76 %)
- No fumadoras
- Bajo riesgo
- 18.1 % enfermedad

Cluster 1

- Hombres (87 %)
- Fumadores
- Enfermedad severa
- 84 % casos severos

Cluster 2

- Hombres (85 %)
- Jóvenes (47.8 años)
- Riesgo intermedio
- 25 % enfermedad

Limitaciones Identificadas

- **Tamaño muestral:** 282 observaciones
- **Desbalance de clases:** Afecta métricas
- **Variables faltantes:** cigs no disponible en formato final
- **Formato complejo:** Dificultades en lectura original

- **Red Neuronal:** Modelo óptimo (F1-Score: 0.8462)
- **Clustering:** Identificación de 3 perfiles naturales
- **Variables clave:** Género y tabaquismo determinantes
- **Metodología robusta:** Limpieza rigurosa y validación exhaustiva

- **Clasificación multiclase:** A pesar del desbalance
- **Variables adicionales:** Estilo de vida.

¡Gracias!

¿Preguntas?